

# Predição de séries temporais de radiação solar utilizando modelos estatísticos e aprendizagem profunda na região de Quixeramobim - CE

Raul Victor de O. Paiva \* Tarcisio F. Maciel \*\* Wilker de O. Feitosa \*\*\*  
Nícolas de A. Moreira \*\*\*\*

\* Departamento de Engenharia de Teleinformática, Universidade Federal do Ceará, CE, (e-mail: raul.paiva@alu.ufc.br).

\*\* Departamento de Engenharia de Teleinformática, Universidade Federal do Ceará, CE (e-mail: maciel@gtel.ufc.br)

\*\*\* Departamento de Engenharia de Teleinformática, Universidade Federal do Ceará, CE (e-mail: wilker@gtel.ufc.br)

\*\*\*\* Departamento de Engenharia de Teleinformática, Universidade Federal do Ceará, CE (e-mail: nicolas.araujom@gmail.com)

---

**Abstract:** Weather forecasting is essential in the renewable energy sector, and it is indispensable to use climate informations such as air humidity, atmospheric pressure, temperature, wind speed and solar irradiation, which can be considered variables for forecasts in a certain region. In particular, there is a notable potential for the use of photovoltaic solar energy in the Brazilian Northeast due to the high solar irradiation levels in the region and, from the climatic time series, it is possible to train deep learning models that seek to predict the short and long term. This work aims to statistically analyze and predict a time series of total daily solar irradiation in the municipality of Quixeramobim, Ceará, through machine learning methods. The results obtained indicate that the models predict solar irradiance with low prediction error when compared to existing results in the literature. However, it is still necessary to investigate whether variables such as precipitation levels and temperature influence the predictions obtained in the study.

**Resumo:** A previsão do tempo é fundamental no setor de energias renováveis, sendo indispensável o uso de informações climáticas como umidade do ar, pressão atmosférica, temperatura, velocidade do vento e incidência de radiação solar, as quais podem ser consideradas variáveis para previsões em uma determinada região. Em particular, há um notório potencial para o emprego de energia solar fotovoltaica no Nordeste brasileiro devido à grande incidência de radiação solar na região e, a partir das séries temporais climáticas, é possível treinar modelos de aprendizagem profunda que busquem prever a curto e longo prazo a irradiação solar. Este trabalho visa analisar estatisticamente e prever uma série temporal de incidência de radiação solar total diária no município de Quixeramobim, no Ceará, através dos métodos de aprendizagem de máquina. Os resultados obtidos indicam que os modelos predizem a irradiação solar com erro de predição baixo quando comparado a resultados existentes na literatura. Contudo, é necessário ainda investigar se variáveis como níveis de precipitação e temperatura influenciam as previsões obtidas no estudo.

**Keywords:** solar irradiation; time series; data analysis; machine learning; data science

**Palavras-chaves:** radiação solar; séries temporais; análise de dados; aprendizado de máquina; ciência de dados

---

## 1. INTRODUÇÃO

Atualmente, o avanço tecnológico fornece recursos essenciais no auxílio à tomada de decisões em áreas diversas, como na Economia, Finanças e Gestão Ambiental.

Em particular, para modelos de predição de séries temporais de dados climáticos, ainda existem limitações de processamento computacional pelo fato dos modelos numéricos clássicos, como os Modelos Numéricos de Circulação Geral (MCGs), serem muito complexos. De fato, os MCGs usam equações matemáticas representativas das leis físicas que regem os movimentos da atmosfera e as interações com os componentes do sistema climático e cuja solução depende de métodos

numéricos de altíssima demanda computacional (Escobar, 2007; Sampaio and Dias, 2014). A partir daí surge a necessidade de investigar novos métodos de predição de séries temporais climáticas, mais simples, com menor custo computacional, e que forneçam bons resultados, sejam eles estatísticos ou baseados em Redes Neurais Artificiais (RNAs).

Neste contexto, a metodologia clássica usando o método *Autoregressive Integrated Moving Average* (ARIMA), também conhecida como metodologia de Box-Jenkins, é uma abordagem comumente utilizada em predição de séries temporais, buscando expressar o comportamento futuro das séries baseado na variação estatística de seus dados no passado. O método ARIMA é considerado um método clássico devido à sua generalidade,

podendo lidar com séries estacionárias ou não-estacionárias, sem ou com elementos sazonais Babai et al. (2013); Maddala (2003), sendo este último caso tratado pelo método *Sazonal ARIMA* (SARIMA).

Além dos modelos clássicos, RNAs vêm sendo empregadas com sucesso na predição de séries temporais por sua capacidade generalizada de aproximar funções não-lineares (Fernandes et al., 1996; Calôba et al., 2002; Torres-Jr et al., 2005).

De fato, conforme Mourao (2019); Teixeira et al. (2019); Pereira (2017); Ghaderi et al. (2017); Grover et al. (2015), é viável treinar modelos preditivos de Aprendizagem Profunda (AP) a partir de séries temporais. A mesma conclusão é tomada em Santos and Costa (2013) em que se afirma que os instrumentos utilizados pelos meteorologistas foram se desenvolvendo e, com eles, a precisão das previsões do tempo foi melhorada substancialmente. Assim, o uso de AP neste trabalho para predição de séries temporais climáticas encontra parte de sua justificativa.

Por outro lado, no contexto socioeconômico a participação das fontes fósseis na matriz energética mundial é de 79,5% e, em 2017, 179 países tinham metas para aumentar essa participação em suas matrizes energéticas, um número que vem crescendo ao longo dos anos seguindo a introdução de novas políticas regulatórias para energias renováveis (REN21, 2018). No caso dos grandes empreendimentos para geração elétrica a partir da energia solar fotovoltaica no Brasil, uma expansão, iniciada em 2014 com os primeiros projetos de Usinas Fotovoltaicas (UFVs) vencedores de leilões de energia, é atribuída à redução dos custos de investimento, ao aumento da capacidade das usinas e à estimativa convidativa sobre a redução dos custos do empreendimento no horizonte de entrega da energia (EPE, 2018).

Em Mendes et al. (2017), aponta-se que o aumento das usinas fotovoltaicas demandará dos responsáveis pela operação de sistemas elétricos a aplicação de ferramentas capazes de prever a disponibilidade de recursos solares em curto prazo, em particular com o uso de RNAs na predição da radiação solar global. Lá destaca-se ainda que métodos de predição com RNAs podem ser aplicáveis a quaisquer regiões do Brasil, até mesmo àquelas em que não há estações de monitoramento suficientes, dada a capacidade de generalização das RNAs.

Como pode ser visualizado na 1, o nordeste brasileiro possui grande potencial para ampliação da energia fotovoltaica como matriz energética. No contexto regional, o Governo do Estado do Ceará tem favorecido e atraído investidores no setor das energias renováveis. Conforme EPE (2018), no leilão A-4/2018 para contratação de projetos de energia solar, dentre 29 empreendimentos que foram contratados no Brasil, 14 deles são no Ceará, totalizando 390 MW de potência a ser instalada no estado. Deste modo, a justificativa e relevância de estudos como o conduzido neste trabalho são fortalecidas e o trabalho atual encontra-se portanto alinhado às iniciativas do Governo do Estado.

Através de técnicas de aprendizagem de máquina, é possível realizar um amplo estudo referente a séries temporais climáticas nas regiões do sertão central cearense, fornecendo previsões de temperatura e incidência de radiação solar, por exemplo, em uma área específica do Ceará. Logo, este trabalho colabora com o desenvolvimento do setor de energia solar no Estado.



Figura 1. Irradiação solar no território Brasileiro. Média dos anos 1999 a 2011. Fonte: <http://solargis.info>.

Neste trabalho foi abordado o treinamento de modelos preditivos para séries temporais de incidência de radiação solar a fim de mapear parte do potencial fotovoltaico da região de Quixeramobim-CE, utilizando AP com o *Long Short-Term Memory* (LSTM), bem como os métodos estatísticos ARIMA e SARIMA.

O restante deste artigo está organizado como segue. A 2 revisita brevemente as séries temporais, os métodos estatísticos ARIMA e SARIMA, e o método LSTM de AP. A 3 apresenta a metodologia utilizada e os valores aplicados na parametrização dos estudos realizados, bem como realiza a discussão dos resultados obtidos através da análise do histograma, da densidade de probabilidade, das funções de autocorrelação e de autocorrelação parcial dos dados das séries temporais, além da aplicação de testes de estacionariedade e de tendência, e apresenta a comparação entre os métodos investigados. A 4 contém as principais conclusões obtidas a partir dos resultados obtidos e aponta algumas perspectivas de trabalhos futuros.

## 2. MODELAGEM DE SÉRIES TEMPORAIS DE RADIAÇÃO SOLAR

### 2.1 Séries temporais climáticas e os modelos ARIMA

Séries de dados colhidos ao longo do tempo são chamadas de séries temporais e, quando se referem a dados climáticos, são chamadas de séries temporais climáticas. Séries temporais climáticas, como temperatura, pressão atmosférica, velocidade do vento e incidência de radiação solar, podem ser encontradas em bases de dados de órgãos competentes como o Instituto Nacional de Meteorologia (INMET) e a Fundação Cearense de Meteorologia e Recursos Hídricos (FUNCEME), entre outros, subsidiando estudos que abrangem a temática de previsões de fenômenos/eventos climáticos.

Uma série temporal  $y_{t=1}^T$ ,  $t = 1, \dots, T$  é normalmente uma realização particular de um processo estocástico que pode ser representada como:

$$y_{t=1}^T = \{y_1, y_2, \dots, y_t, \dots, y_{T-1}, y_T\}. \quad (1)$$

Através da análise dos dados contidos na série, diversas propriedades de interesse, como média, variância, periodicidade e estacionariedade, entre outras, dos dados podem ser extraídas a partir da aplicação de métodos estatísticos. Estas informações podem fornecer informações importantes sobre o fenômeno subjacente aos dados e auxiliar na tomada de decisões.

Como demonstrado em Sampaio and Dias (2014); Teixeira et al. (2019); Grover et al. (2015); Mendes et al. (2017), a partir de séries temporais climáticas é possível construir modelos preditivos utilizando a modelagem clássica ARIMA e suas variantes, assim como as RNAs de AP. Além disso, é de conhecimento geral que modelos de AP permitem avaliar uma quantidade maior de parâmetros, capturando os padrões ocultos nos dados das séries temporais tornando-se, portanto, uma ferramenta de grande potencial para a área.

Passando à breve discussão sobre os modelos ARIMA, os mesmos são normalmente caracterizados por três parâmetros:

- $p$ : o número de observações passadas incluídas no modelo, também conhecido como “ordem de lag”, associadas ao componente Autoregressivo (AR) do método;
- $d$ : o número de diferenças tomadas ou “grau de diferenciação”, associadas ao componente integrativa do método e que busca estabelecer estacionariedade;
- $q$ : o tamanho da janela de média móvel ou “ordem de média móvel”, associada a componente de Média Móvel (MA) do método.

Um modelo ARIMA é usualmente representado pela notação ARIMA( $p, d, q$ ).

No contexto dos modelos ARIMA, a metodologia Box-Jenkins investiga a autocorrelação entre valores da série em diferentes instantes sucessivos de tempo. Os padrões de autocorrelação, em geral, possibilitam identificar um ou vários modelos possíveis para a série temporal Mehdi and Mehdi (2010).

De forma similar ao ARIMA, o SARIMA possui os parâmetros  $p, d, q$  associados à parte não-sazonal do processo estocástico subjacente Chen and Wang (2007) e possui outros 4 parâmetros associados à parte sazonal do mesmo:

- $P$ : ordem da componente AR sazonal;
- $D$ : ordem de diferenças sazonais;
- $Q$ : ordem da componente MA sazonal;
- $s$ : número de períodos referentes ao ciclo sazonal.

Em síntese, o modelo SARIMA lida com a componente sazonal da série temporal e, por isso, o mesmo pode oferecer melhores resultados para dados que possuam sazonalidade inerente, como dados climáticos que são afetados pelas estações do ano.

Uma descrição mais aprofundada do método ARIMA e suas variantes está fora do escopo deste trabalho, mas podem ser encontradas, por exemplo, em Calôba et al. (2002); Mehdi and Mehdi (2010); Chen and Wang (2007).

## 2.2 RNR e LSTM

Conforme resume Teixeira et al. (2019), as Redes Neurais Recorrentes (RNRs) são representadas por uma realimentação na arquitetura padrão. O alcance dos valores utilizados para correção dos pesos é restrito, pois a influência da saída nas camadas ocultas decai exponencialmente à medida em que passa pelas conexões recorrentes da rede. Várias tentativas para resolver esta questão, conhecida como problema de dissipação

de gradiente, foram abordadas durante os anos 90, e uma das soluções adotadas foi a criação das redes LSTM.

A ideia central por trás da arquitetura LSTM é uma atualização da memória  $C_n$ . O bloco de memória LSTM está ilustrado na 2.




Figura 2. Representação de uma célula LSTM Rasmus et al. (2019).

Agora o mesmo possui a capacidade de remover ou adicionar informações a esta memória em cada passo de tempo em uma sequência, controlada cuidadosamente por um *forget gate*  $f_n$  e um *input gate*  $i_n$ , que empregam a mesma estrutura de uma rede neural de única camada com a função de ativação sigmoide Rasmus et al. (2019), e se relacionam com os demais de elementos (pesos, entradas, saídas, vieses, etc.) segundo a equação

$$f = \varphi(b_f + \mathbf{u}_f^T \mathbf{x}_n + \mathbf{w}_f^T \mathbf{h}_{n-1}), \quad (2a)$$

$$i_t = \varphi(b_i + \mathbf{u}_i^T \mathbf{x}_n + \mathbf{w}_i^T \mathbf{h}_{n-1}). \quad (2b)$$

Os autores em Rasmus et al. (2019) ressaltam que  $\mathbf{x}_n$  é a sequência de entrada no passo de tempo  $n$ , e  $\mathbf{h}_{n-1}$  é o vetor de saída da LSTM no passo de tempo passado. Os parâmetros  $\mathbf{u}_i, \mathbf{w}_i, \mathbf{u}_f$  e  $\mathbf{w}_f$  são as entradas e os vetores de peso recorrentes do *input* e *forget gates*, respectivamente, em que os  $b$ 's são todos os termos dos vieses. Os autores ainda ressaltam que a função de ativação sigmoide é responsável por controlar o quanto de cada componente deve passar. Ainda segundo Rasmus et al. (2019), a memória  $C_n$  é atualizada esquecendo parcialmente a memória existente e adicionando um novo conteúdo de memória  $C_{\tilde{n}}$  dado por

$$C_n = f_n C_{n-1} + i_n \tilde{C}_n, \quad (3a)$$

$$\tilde{C}_n = \tanh(b_c + \mathbf{u}_c^T \mathbf{x}_n + \mathbf{w}_c^T \mathbf{h}_{n-1}). \quad (3b)$$

O *output gate*  $o_n$  possui estrutura familiar à do *input* e *forget gate*. A saída da LSTM é dada por

$$h_n = o_n \tanh(C_n), \quad (4a)$$

$$o_n = \tanh(b_o + \mathbf{u}_o^T \mathbf{x}_n + \mathbf{w}_o^T \mathbf{h}_{n-1}), \quad (4b)$$

em que os termos  $\mathbf{u}_o$  e  $\mathbf{w}_o$  são os vetores de peso de entrada e recorrente do *output gate*, respectivamente Rasmus et al. (2019). Uma análise mais detalhada de RNRs, LSTM, e suas aplicações, foge ao escopo deste trabalho, sendo o leitor interessado em descrições mais aprofundadas direcionado às referências (Rasmus et al., 2019; Ghaderi et al., 2017; Pereira, 2017).

### 3. ANÁLISE DOS RESULTADOS

Nos estudos realizados neste trabalho utilizaram a linguagem de programação Python para a modelagem e análise dos dados. Em particular, o método ARIMA foi acessado a partir da biblioteca `statsmodels` (Seabold and Perktold, 2010). Para a otimização dos parâmetros, o método *walk-forward* foi utilizado. Os parâmetros  $p$  e  $q$  dos modelos ARIMA e SARIMA foram determinados através de uma busca direta nos intervalos  $0 \leq p \leq 9$  e  $0 \leq q \leq 4$ , respectivamente, enquanto que  $d = 0$  foi adotado não tendo sido portanto diferenciada a série.

A série de radiação solar coletada na região de Quixeramobim foi acessada na base de dados públicos da página oficial do INMET. A 3 apresenta a série temporal completa, com 1827 observações, juntamente com a decomposição da série nas componentes de tendência, sazonalidade e resíduo.




Figura 3. Decomposição da série completa nas componentes de tendência, sazonalidade e erro (resíduo).

A decomposição foi realizada a partir da função `statsmodels.tsa.seasonal.seasonal_decompose` do módulo `statsmodels` em Python. É possível observar uma tendência crescente em determinadas épocas e decrescente em outras. A sazonalidade, com frequência equivalente a 365 pontos, apresenta uma série que possui um padrão intrínseco. É possível observar o extenso nível de erro a partir do gráfico residual.

Na 4, nota-se no histograma e distribuição de densidade de probabilidade que a maior incidência de radiação está entre 9 a 11  $\text{KJ/m}^2$ .




Figura 4. Histograma e densidade de probabilidade da série de radiação solar.

As análises indicadas acima são importantes para melhor compreensão dos dados em questão. Todavia, é necessário

Tabela 1. Resultados dos testes ADF e MK do conjunto de dados de Quixeramobim.

Série	ADF	Valor $p$	MK	Valor $p$
Original	-5,70	$7,60 \times 10^{-7}$	$-1,95 \times 10^{-4}$	$1,73 \times 10^{-2}$
Diferenciada	-15,90	$7,80 \times 10^{-29}$	0,00	$9,93 \times 10^{-1}$

avaliar os parâmetros necessários para iniciar a modelagem com os métodos ARIMA. As análises da *Autocorrelation Function* (ACF) e *Partial ACF* (PACF) pode ajudar nesta avaliação. Na 5, pode-se notar que a ACF, com nível de significância equivalente a 5%, revela o intervalo de confiança até por volta de 20 lags, pois conforme os dados de comparação são afastados, o resultado da correlação se aproxima de 0. Verifica-se na PACF uma significância em até 3 lags. Estas avaliações são importantes para a determinação inicial dos parâmetros do modelo ARIMA, uma vez que os lags na ACF ajudam a definir o parâmetro  $q$  da média móvel, enquanto os da PACF definem o  $p$  da autorregressão.




Figura 5. Funções de autocorrelação e autocorrelação parcial.

Ainda sobre os parâmetros do modelo ARIMA, também é possível verificar inicialmente se é necessário utilizar algum grau de diferenciação ( $d$ ) na série, para isto, o teste *Augmented Dickey-Fuller* (ADF) fornece as respostas necessárias. Ao realizar a análise de séries temporais, é necessário verificar a estacionariedade Vasconcellos (2000). Portanto, teste ADF foi realizado em que a hipótese nula foi testada para a investigação da estacionariedade, com nível de significância equivalente a 5%. Para análise de tendência, culminando em um estudo mais apurado, foi realizado o teste de *Mann-Kendall* (MK), pois segundo Goossens and Berger (1986) o teste de MK é o método mais apropriado para analisar mudanças climáticas, além de permitir a detecção e localização aproximada do ponto inicial de determinada tendência.

O teste MK retornou tendência decrescente para a série original, como pode ser observado na 3, e nula para a série diferenciada com ordem 1.

**PAREI AQUI. FAZER O ELO ENTRE A "POSSIBILIDADE DA MODELAGEM" E "SEPARAÇÃO DE TREINO E TESTE"!** Com tudo, tendo em vista a análise prévia da série de radiação solar no município de Quixeramobim, foi possível criar modelos preditivos com os clássicos ARIMA e SARIMA, e com a LSTM de AP. Para isto, foi... . Na 6 abaixo, segue a divisão da base de treino e teste. A divisão da base de dados consta em 80% de treino, que equivale ao período de janeiro de 2015 a dezembro de 2018.






Figura 6. Divisão da base de treino e teste.




Figura 7. Predição com o modelo ARIMA(5, 0, 3).




Figura 8. Predição com o modelo SARIMA(5, 0, 3)(4, 0, 4, 12).




Figura 9. Predição com o modelo LSTM.

Base de Teste			
MODELOS	MAPE (%)	MAE	RMSE (kJ/m2)
ARIMA	52.81	1.83	2.38
SARIMA	69.33	2,47	2.57
LSTM	51.27	1.82	2.34

## 4. CONCLUSÃO

### AGRADECIMENTOS

Coloque aqui seus agradecimentos.

### REFERÊNCIAS

- Able, B. (1956). Nucleic acid content of microscope. *Nature*, 135, 7–9.
- Able, B., Tagg, R., and Rush, M. (1954). Enzyme-catalyzed cellular transaminations. In A. Round (ed.), *Advances in Enzymology*, volume 2, 125–247. Academic Press, New York, 3rd edition.
- Babai, M.Z., Ali, M.M., Boylan, J.E., and Syntetos, A.A. (2013). Forecasting and inventory performance in a two-stage supply chain with arima (0, 1, 1) demand: Theory and empirical analysis. *International Journal of Production Economics*, 143(2), 463–471.
- Calôba, G.M., Calôba, L.P., and Saliby, E. (2002). Cooperação entre redes neurais artificiais e técnicas clássicas para previsão de demanda de uma série de vendas de cerveja na Austrália. *Pesquisa Operacional*, 22, 345–358.
- Chen, K.Y. and Wang, C.H. (2007). A hybrid sarima and support vector machines in forecasting the production values of the machinery industry in Taiwan. *Expert Systems with Applications*, 32(1), 254–264.
- EPE (2018). *Projetos fotovoltaicos nos leilões de energia: Características dos empreendimentos participantes nos leilões de 2013 a 2018*. Empresa de pesquisa energética.
- Escobar, G.C.J. (2007). Padrões sinóticos associados a ondas de frio na cidade de São Paulo. *Revista Brasileira de Meteorologia*, 22, 241–254.
- Fernandes, L.G.L., Portugal, M.S., and Navaux, P.O.A. (1996). Previsão de séries de tempo: redes neurais artificiais e modelos estruturais. *Pesquisa e Planejamento Econômico*, 26(2), 253–276.
- Ghaderi, A., Sanandaji, B.M., and Ghaderi, F. (2017). Deep forecast: Deep learning-based spatio-temporal forecasting. In *The 34th International Conference on Machine Learning (ICML), Time series Workshop*.
- Goossens, C. and Berger, A. (1986). Annual and seasonal climatic variations over the northern hemisphere and Europe during the last century. In *Annales Geophysicae*, volume 4, 385–400.
- Greff, K., Srivastava, R.K., Koutník, J., Steunebrink, B.R., and Schmidhuber, J. (2016). Lstm: A search space odyssey. *IEEE transactions on neural networks and learning systems*, 28(10), 2222–2232.
- Grover, A., Kapoor, A., and Horvitz, E. (2015). A deep hybrid model for weather forecasting. In *Proceedings of the 21th ACM SIGKDD international conference on knowledge discovery and data mining*, 379–386.
- Keohane, R. (1958). *Power and Interdependence: World Politics in Transitions*. Little, Brown & Co., Boston.
- Maddala, G.S. (2003). *Introdução à econometria*. Rio de Janeiro: LTC, third edition.
- Mehdi, K. and Mehdi, B. (2010). An artificial neural network (p, d, q) model for timeseries forecasting. *Expert Systems with applications*, 37(1), 479–489.
- Mendes, I.A., Rezende, R.A.D., Ferreira, T.H., e Silva Nascimento, J.S.F., and Silva, O.F. (2017). A utilização das redes neurais artificiais na previsão de radiação solar global. In

- Congresso Técnico Científico da Engenharia e da Agronomia. Belém-PA.*
- Mourao, I.S. (2019). Predição de séries temporais climáticas com aprendizagem profunda.
- Pereira, M.M. (2017). Aprendizado profundo: Redes lstm.
- Powers, T. (1985). Is there a way out? *Harpers*, 35–47.
- Rasmus, A.S., Peimankar, A., and Puthusserypady, S. (2019). A deep learning approach for real-time detection of atrial fibrillation. *Expert Syst. Appl.*, 115, 465–473.
- REN21 (2018). *Renewables 2018 global status report. A comprehensive annual overview of the state of renewable energy.* Renewable energy policy network for the 21st century.
- Sampaio, G. and Dias, P.S. (2014). Evolução dos modelos climáticos e de previsão de tempo e clima. *Revista USP*, (103), 41–54.
- Santos, A. and Costa, O.A. (2013). Sistema de recepção de dados do satélite meteosat-9 na secretaria de meio ambiente e recursos hídricos—sergipe: Implementação e aplicações. In *Anais XVI Simpósio Brasileiro de Sensoriamento Remoto - SBSR*.
- Seabold, S. and Perktold, J. (2010). statsmodels: Econometric and statistical modeling with python. In *9th Python in Science Conference*. URL <https://www.statsmodels.org/stable/index.html>.
- Teixeira, R., Silva, D., Mello-Junior, H., Forero, L., Lima, A., and Figueiredo, K. (2019). Previsão de séries temporais de velocidade do vento utilizando redes neurais artificiais e métodos estatísticos na região de arraial do cabo-rj. In *Anais do 14 Congresso Brasileiro de Inteligência Computacional*, 1–7. ABRICOM.
- Torres-Jr, R.G., Machado, M.A.S., and Souza, R.C. (2005). Previsão de séries temporais de falhas em manutenção industrial usando redes neurais. *Engevista*.
- Vasconcellos, M.A.S. (2000). *Manual de econometria*. São Paulo: Editora Atlas, first edition.